

# 多层感知机

2020年5月15日 星期五

22:01


多层感知机与全连接层类似

基本结构就是在每个隐含层后加上激活函数

多层感知机(全连接网络)的灵魂就在于反向传播过程

也是后面所有深度学习的基础,

假设有这样一个网络



注意这里的 $w$ . 感知机的 $w$ 不一样. 前面感知机的 $w$ 是一个向量

这里的 $w$ 是一个数字. 前面的输入层有两个神经元. 可以看作是输入是一个二维向量. 向量中两个值分别进入 $i_1$ 和 $i_2$

这里  $b_1$  和  $b_2$  是两个偏置. 一般一整个层共用一个偏置

现在假设一个数据集是  $(0.05, 0.1) - (0.01, 0.99)$

设初始权重为  $w_1 = 0.15$   $w_2 = 0.2$   $w_3 = 0.25$   $w_4 = 0.3$   $b_1 = 0.35$

$w_5 = 0.4$   $w_6 = 0.45$   $w_7 = 0.5$   $w_8 = 0.55$   $b_2 = 0.6$

现在来模拟前向传播过程

(1). 输入层到隐含层

$h_1$  的输入:  $h_{1in} = w_1 \cdot i_1 + w_2 \cdot i_2 + b_1$

$$= 0.15 \times 0.05 + 0.2 \times 0.1 + 0.35 = 0.3775$$

$h_1$  的激活函数 (sigmoid) 后的输出:

$$h_{1out} = \frac{1}{1 + e^{-h_{1in}}} = \frac{1}{1 + e^{-0.3775}} = 0.5932$$

同理算出  $h_{2out} = 0.5968$

(2). 隐含层到输出层

## (2). 隐含层到输出层

$$O_1 \text{ 的输入: } O_{1, \text{in}} = w_5 \cdot h_{1, \text{out}} + w_6 \cdot h_{2, \text{out}} + b_2$$

$$= 0.4 \times 0.5932 + 0.45 \times 0.5968 + 0.6 = 1.1059$$

$$O_1 \text{ 的输出: } O_{1, \text{out}} = \frac{1}{1 + e^{-O_{1, \text{in}}}} = 0.7513$$

$$\text{同理, } O_2 \text{ 的输出 } O_{2, \text{out}} = 0.7729$$

此时前向传播结束, 得到的输出为  $(0.7513, 0.7729)$  与  $(0.01, 0.99)$  相差甚远

所以需要反向传播, 更新权重

## 损失函数

$$E = \sum \frac{1}{2} (\text{target} - O_{\text{out}})^2$$

$$= \frac{1}{2} (0.01 - 0.7513)^2 + \frac{1}{2} (0.99 - 0.7729)^2 = 0.2983$$

最终目的就是使  $E$  尽量小.

## (1). 输出层到隐含层

例如现在我们要更新  $w_5$  的权重, 需要知道  $E$  在  $w_5$  上的梯度方向, 所以对  $w_5$  求偏导

$$\frac{\partial E}{\partial w_5} = \frac{\partial E}{\partial O_{1, \text{out}}} \cdot \frac{\partial O_{1, \text{out}}}{\partial O_{1, \text{in}}} \cdot \frac{\partial O_{1, \text{in}}}{\partial w_5}$$

链式法则, 这是反向传播的根本.  
同时也表明损失函数和激活函数必须可导

$$\frac{\partial E}{\partial O_{1, \text{out}}} = \frac{\partial \sum \frac{1}{2} (\text{target} - O_{\text{out}})^2}{\partial O_{1, \text{out}}} = 2 \cdot \frac{1}{2} (\text{target} - O_{1, \text{out}})^{2-1} \cdot (-1) = 0.7413$$

$$\frac{\partial O_{1, \text{out}}}{\partial O_{1, \text{in}}} = \frac{\partial \frac{1}{1 + e^{-O_{1, \text{in}}}}}{\partial O_{1, \text{in}}} = 0.1868 \quad (\text{sigmoid 的导数})$$

$$\frac{\partial O_{1, \text{in}}}{\partial w_5} = \frac{\partial w_5 \cdot h_{1, \text{out}} + w_6 \cdot h_{2, \text{out}} + b_2}{\partial w_5} = h_{1, \text{out}} = 0.5932$$

$$\text{最终结果 } \frac{\partial E}{\partial w_5} = 0.08216$$

若设学习率  $\eta = 0.5$

则更新  $w_5$  为  $w_5 - \eta \frac{\partial E}{\partial w_5}$


若设学习率  $\eta = 0.5$

则更新后的  $w_r^+ = w_r - \eta \cdot \frac{\partial E}{\partial w_r} = 0.4 - 0.5 \times 0.08216 = 0.3589$

同理可更新  $w_6^+ = 0.4086$   $w_7^+ = 0.5113$   $w_8^+ = 0.4613$

## (2) 隐含层到输入层

原理与之前相同。区别是，上面更新  $w_i$  时，只要求从  $O_i \rightarrow h_i$  的路径即可。但更前一层的  $w_i$  还受  $O_i$  影响



$$\frac{\partial E}{\partial w_1} = \frac{\partial E}{\partial h_{out}} \cdot \frac{\partial h_{out}}{\partial h_{in}} \cdot \frac{\partial h_{in}}{\partial w_1}$$

$$\frac{\partial E}{\partial h_{out}} = \frac{\partial \sum \frac{1}{2} (target - O_{out})^2}{\partial h_{out}} = \frac{\partial E}{\partial O_{out}} \cdot \frac{\partial O_{out}}{\partial O_{in}} \cdot \frac{\partial O_{in}}{\partial h_{out}} + \frac{\partial E}{\partial O_{out}} \cdot \frac{\partial O_{out}}{\partial O_{in}} \cdot \frac{\partial O_{in}}{\partial h_{out}}$$

$w_1$   $w_6$

这时候用  $w_1$  计算时用的是没更新的  $w_1$

这样计算完成之后  $\frac{\partial E}{\partial w_1} = 0.0004385$

$$w_1^+ = w_1 - \eta \cdot \frac{\partial E}{\partial w_1} = 0.1497$$

这样即可完成权值更新